# 格致：一个把学生放上「教师」位置的本地优先 AI 学习伙伴

2026 年全球青少年人工智能未来创新竞赛 • 澳门中学生赛区

主题：AI 与教育

队伍 *[队伍名称]* · *[学校名称]* · 澳门

## 1. 问题

生成式人工智能被寄予厚望，被认为终于能让每个学生都拥有一位私人导师。但最早的一批严谨证据给出的答案要复杂得多，而且两个方向的结论同时成立。

| 研究 | 设计 | 结论 |
|---|---|---|
| Bastani 等（2024） | 随机对照实验；土耳其约 1000 名高中生；数学 | 可无限制使用 ChatGPT 的组：练习正确率 **+48%**，但撤掉 AI 后考试**低 17%**。使用" 只给提示、不给答案" 的导师版：练习 **+127%**，但考试**与不用 AI 的对照组没有差别**。 |
| Oreopoulos 与 Low（2026） | 两年整群随机对照实验；美国田纳西州 18 所初中；AI 被配置成只引导不给答案 | 效应仅 **0.06–0.08 个标准差**，与" 同一平台不用 AI" 相当。瓶颈是行为而非技术：中位数学生只在**三分之一的练习日**使用它，在做错题的场次中只有 **17%** 会去求助。 |

把这两项研究放在一起看，指向的是同一条窄缝：**今天的 AI 导师只有两种结局——要么有害，要么无人使用**。而且" 把 AI 做得更克制" 并不能解决第二个问题：一个被刻意设计成只给提示的导师同样没有产生可测量的收益，因为学生根本不去打开它。唯一从未被证明会损害学习的条件，是**由学生自己产出解释**的那一个。

## 2. 目标使用者

**主要使用者**：澳门的中学生（中三至中六，约 14–18 岁），正在准备校内考试与大学入学。我们具体瞄准的是这样一种学生——他感觉自己懂了，却讲不出来。这种" 懂了错觉" 并非个例：综合 115 项研究、15889 名学习者、502 个效应量，学生对自己掌握程度的判断与实际成绩之间的加权平均相关只有 $r = .178$（Yang 等，2022）。

**次要使用者**：需要知道一个班*真正*理解了什么（而不只是做完了什么）的学科教师；以及希望看到比" 学习时长" 更有信息量的东西的家长。

## 3. 主要功能

格致是一款 Windows 桌面学习应用，整款产品围绕一个循环组织：**先暴露无知，再产出解释，被质疑，然后掌握**。

- **知识库**。学生自己的课程材料——教材、讲义、笔记、扫描的练习卷——在本地建立索引，中英文皆可检索。任何内容都不上传。
- **题库与组卷**。题目按知识点标注，可导出为排版规范的试卷；另有*交错模式*，把不同知识点混排，并刻意*不标注*每道题属于哪个知识点。
- **讲述与答辩（核心）**。学生把某个知识点讲给屏幕上的伙伴「小格」听。小格被刻意设定成*比他低一个年级*，并且带着一套固定的错误理解。它不会点头附和，而是会反驳。系统按六维评分表打分，并记录" 用了几个回合才真正说服它"。
- **间隔复习与计划**。每个知识点带一个掌握度估计，并据此同时排程*题目和讲解*。
- **不看分数也能看到进步**。小格头顶有一个九宫格。九格全空表示它什么都还不懂；每成功讲清一

次，就亮起一格。学生不必读数字就知道自己走到哪里了。

## 4. AI 方法

格致没有自己实现 Agent 循环。推理层采用 **DeepSeek Harness（DSH）**——一个 MIT 许可的 Agent 内核，以受控子进程方式调用，并输出按行分隔的 JSON 事件流。会话持久化、工具沙箱、上下文压缩与审批策略由此直接复用，这些都不是一个中学生团队应当从零重造的部分。其中三个技术决定最关键：

**一、知识库本身就是沙箱。**子进程的工作目录被设为学生的知识库，内核据此推导出写入边界。AI 能读写学生自己的笔记，除此之外什么也碰不到——这条边界由操作系统的进程模型强制，而不是靠提示词里的嘱咐。

**二、中文检索需要一个不那么显然的修复。**我们实测发现，SQLite 默认的 FTS5 分词器对中文子串查询返回零结果，因为它把一整句中文当成一个词元。改用 `tokenize='trigram'` 后恢复正常：在 200 份文档上查询延迟约 1 ms。因此检索完全在本地、离线进行，并且是可溯源的——系统给出的每一条论断都锚定在学生自己教材的某一页上。

**三、这个伙伴是被刻意设计成会犯错的。**一份误解库（来自学生自己的错题统计）被注入小格的人格提示词，同时加了一条硬约束：**在学生的解释真正命中该误解的纠正要点之前，它不得表示理解。**这一设计依据两项研究：CHI 2025 的工作表明可教代理必须装笨才有教学价值；而另一项对照实验发现，当 AI 直接给出正确答案时，学生的纠错能力**完全没有提升**。

## 5. 创新点

我们不声称发明了”以教促学”。可教代理的研究最早可追溯到 Chase 等（2009），2024– 2026 年更是一个活跃方向。我们的贡献是四件具体的事：

1. 这类研究绝大多数以**大学生**为对象，且多在计算机课程中开展。我们把它带到了**中学生**面前，做成一款面向他们自己课程的中文桌面产品。
2. 学生教的是**他自己教材里的知识点**，由本地检索提供并附页码引用——而不是通用题目。
3. 我们把”说服小格”这件事变成了**可量化、并能喂给间隔复习排程的分数**，形成闭环，而不是一次性的聊天。
4. 知识库与学习记录**从不离开本机**；模型调用走用户自己的账号，提问内容不做留存。

## 6. 预期影响

我们以学习结果而非使用时长来衡量成败，用三个指标：(1) 一个知识点在”讲述—答辩”前后费曼评分表总分的变化；(2) 学生自评分与评分表得分之间的**校准偏差**，并做长期追踪；(3) 消除一个误解所需的对话回合数——理解越深，回合数应越低。

格致回应的是**可持续发展目标 4（优质教育）**：把通常只有一对一补习才能获得的”解释性练习”带给任何一个有笔记本电脑的学生；同时把 **AI 素养**本身当作一个学习目标——能诊断并纠正 AI 错误理解的学生，才算真正知道这类系统会在哪里出错。这一点直接对应 UNESCO《学生人工智能能力框架》（2024）中”AI 系统设计”维度的”创造”层级。

## 7. 目前进展

一个可运行的原型已在 Windows 上跑通上述完整闭环：中英混合材料的本地索引、带引用的检索、与小格的语音讲述会话、评分表打分，以及导出排版试卷。误解库目前有 【待填：条数】 条，覆盖 【待填：科目】。我们已经完成第一轮 【待填：人数】 名中学生的试用，实测结果见配套的《研究报告》。

下一步是加入”不使用 AI”的对照组、用真人评分者校验评分表，并把研究周期拉长到间隔复习排程真正能发挥作用的时间尺度。